

Agente Médico Inteligente Basado en IA: Arquitectura, Implementación y Sistema de Monitoreo Avanzado

Integrantes: Ignacio Mella Cordero, Benjamín Mella Cordero.

Sección: 002D

Fecha: 24/11/2025

Introducción

El presente informe describe el diseño, implementación y mejora de un sistema inteligente de asistencia médica basado en Inteligencia Artificial, cuyo propósito es entregar información clínica estructurada, explicaciones detalladas y orientación preventiva a partir de consultas realizadas por un usuario.

El sistema combina técnicas de *Retrieval-Augmented Generation* (RAG), una arquitectura de agentes, memoria conversacional avanzada, trazabilidad del razonamiento, mecanismos de observabilidad y módulos de seguridad para asegurar un funcionamiento confiable, transparente y eficiente.

El proyecto se desarrolló utilizando Python, Streamlit como interfaz web, LangChain como framework de agentes, ChromaDB para almacenamiento vectorial y modelos de lenguaje alojados en Azure a través de GitHub Models.

Arquitectura General del Sistema

El sistema se compone de dos elementos principales:

Backend: Agente Médico Inteligente

El backend contiene toda la lógica del agente, incluyendo:

- Procesamiento de lenguaje natural
- RAG con PDFs médicos
- Memoria conversacional optimizada
- Herramientas especializadas
- Trazabilidad interna del razonamiento
- Sistema de detección de anomalías
- Métricas de rendimiento
- Validaciones de seguridad

El agente utiliza una clase central que integra:

- El modelo LLM
- Las herramientas de búsqueda y análisis
- La memoria conversacional
- Las funciones de registro, trazabilidad y análisis del sistema

Frontend: Interfaz Web en Streamlit

La interfaz web permite:

- Enviar consultas médicas
- Visualizar la conversación estructurada
- Acceder a estadísticas del sistema
- Consultar trazabilidad interna del agente
- Supervisar el estado de memoria, cache, tokens y rendimiento
- Visualizar gráficas y paneles informativos

La interfaz se organiza en tres pestañas:

1. Chat Médico
2. Estadísticas
3. Ayuda

Procesamiento de Documentos e Infraestructura RAG

El sistema utiliza documentos médicos en formato PDF, los cuales son:

1. Cargados mediante un lector de directorios.
2. Divididos en fragmentos mediante un *Recursive Character Splitter*.
3. Convertidos en *embeddings* usando text-embedding-3-small.
4. Indexados en un almacén vectorial (Chroma).

Con esta infraestructura, las herramientas del agente pueden:

- Buscar síntomas
- Recuperar tratamientos
- Describir medicamentos
- Generar análisis diferenciales
- Validar interacciones

La base de conocimiento es completamente modular, lo que permite agregar nuevos documentos sin modificar la arquitectura.

Sistema de Memoria Conversacional


El agente incorpora dos modalidades:

- Memoria resumida (Summary Memory):
Reduce el crecimiento del historial para mantener eficiencia en sesiones largas.
- Memoria completa (Buffer Memory):
Guarda la conversación completa sin compresión.

Para cada sesión, el sistema muestra:

- Resumen del contexto conversacional
- Tamaño actual de la memoria (KB)
- Número de elementos almacenados
- Nivel de eficiencia

En la interfaz, la memoria se despliega mediante un panel que permite visualizar el resumen actual generado por el agente.



Herramientas Especializadas


El agente cuenta con módulos internos dedicados a funciones específicas:

1. Búsqueda de síntomas
2. Búsqueda de tratamientos
3. Búsqueda de medicamentos
4. Análisis diferencial
5. Validación de interacciones
6. Detección de emergencias
7. Evaluación de relevancia

Estas herramientas permiten que el agente construya respuestas clínicas más precisas y basadas en múltiples fuentes.

Trazabilidad del Razonamiento

El sistema registra paso a paso cómo el agente genera cada respuesta.



Las capturas proporcionadas muestran:

- Una lista de consultas recientes
- Expansores que permiten ver cada paso realizado
- Registros del flujo de razonamiento
- Operaciones realizadas (búsqueda, generación, validación)
- Herramientas utilizadas en cada etapa

Este mecanismo aporta transparencia operativa, facilitando seguimiento, debugging y un entendimiento profundo del comportamiento del agente.

Métricas del Sistema y Estado Interno

Chat Médico Estadísticas Ayuda			
Métricas de Rendimiento			
Total Consultas	Calidad Promedio	Tipo Memoria	Modelo
3	6.0/10	Summary (optimizada)	gpt-4o-mini
Métricas Detalladas			
Observabilidad	Memoria/Contexto	Seguridad	Escalabilidad
Tiempo Promedio	Tamaño Memoria	Alertas Emergencia	Tamaño Cache
16.06s	2.6 KB	0	2
Tasa de Éxito	Elementos	Validaciones	Tokens Totales
66.7%	1287	3	925
Errores	Eficiencia		
1	Alta		

La interfaz incorpora una sección detallada de métricas que incluyen:

Métricas de rendimiento

- Tiempo promedio de respuesta
- Total de consultas
- Calidad promedio de las respuestas
- Cantidad de herramientas utilizadas
- Tokens generados por consulta
- Modelo activo en la sesión

Métricas de observabilidad

- Tasa de éxito
- Número de errores
- Frecuencia de síntomas críticos

Métricas de memoria

- Tamaño total (KB)
- Número de elementos almacenados
- Eficiencia de memoria

Métricas de escalabilidad


- Tamaño de la cache
- Tokens acumulados
- Costo estimado aproximado

Los gráficos de la interfaz permiten visualizar la evolución de la calidad de las respuestas a través del tiempo.

Sistema de Detección de Anomalías

El sistema incluye un monitor avanzado capaz de detectar comportamientos inusuales, tales como:

- Latencia alta
- Picos en el tiempo de respuesta
- Tasa elevada de errores
- Saturación de cache
- Crecimiento anormal de tokens
- Frecuencia de emergencias inesperada



Cuando se detectan anomalías, la interfaz:

- Muestra un mensaje de estado general (Normal, Atención o Crítico)
- Destaca cada anomalía encontrada
- Presenta recomendaciones específicas para corregir o mitigar el problema

En las capturas se observa un estado crítico generado por alta latencia, error rate y picos recientes.

Conversación Médica Estructurada

El sistema presenta las respuestas del agente en un formato clínico ordenado:

- Diagnóstico
- Explicación
- Tratamiento sugerido
- Prevención
- Recomendación
- Indicaciones adicionales

Cada respuesta final incluye:

- Tiempo utilizado
- Puntuación de calidad
- Número de herramientas activadas
- Tokens consumidos

Conversación Médica

Paciente (14:00:30)
tengo fiebre

AI Assistant (16:20:54)
La fiebre es un aumento de la temperatura corporal que puede ser un signo de infección u otra enfermedad subyacente. Aquí podrías tener un análisis de tu situación:
Diagnóstico

- Fiebre: Temperatura corporal elevada, que puede ser incómoda y, en algunos casos, puede llevar a complicaciones como convulsiones febriles, especialmente en niños.

Explicación

La fiebre es una respuesta del cuerpo a infecciones, inflamaciones o enfermedades. Puede estar acompañada de otros síntomas como escalofríos, sudoración, dolor de cabeza, fatiga, entre otros. Es importante identificar la causa subyacente de la fiebre para determinar el tratamiento adecuado.

Tratamiento

1. Medicamentosos antiinflamatorios: Como el paracetamol o el ibuprofeno, que ayudan a reducir la fiebre y aliviar el malestar.
2. Hidratación: Beber líquidos para evitar la deshidratación.
3. Reposo: Permitir que el cuerpo se recupere.

Prevención

- Mantener una buena higiene para prevenir infecciones.
- Vacunarse según las recomendaciones de salud pública.

Recomendación

Dado que la fiebre puede ser un síntoma de diversas condiciones, es importante que busques atención médica si:

- La fiebre es alta (más de 39°C o 102°F).
- Dura más de 3 días.
- Presentas otros síntomas preocupantes (dificultad para respirar, confusión, erupciones cutáneas inusuales, etc.).

Recuerda que esta información no reemplaza la atención médica profesional. Si podrías tener más síntomas o inquietudes, no dudes en consultar a un médico.

⚠️ **AVISO IMPORTANTE:** Esta información es solo educativa y NO reemplaza la consulta con un profesional médico. Ante cualquier duda o síntoma preocupante, consulta con tu médico.

Tiempo
19.25s

Calidad
9.0/10

Herramientas
2

Tokens
~427

Este formato facilita que el usuario comprenda de manera clara y guiada la información entregada por el agente.

Seguridad y Validación

Se incorporaron validaciones para resguardar el uso ético del sistema:

- Detección de solicitudes inapropiadas
- Filtro de contenido peligroso
- Detección de datos sensibles
- Ajustes de lenguaje para evitar diagnósticos absolutos
- Advertencias médicas obligatorias

El sistema protege la integridad de las consultas y evita generar respuestas que puedan interpretarse como un reemplazo a evaluación profesional.

Conclusión

Este proyecto implementa un agente médico inteligente robusto, escalable y transparente, capaz de entregar orientación clínica estructurada utilizando datos médicos confiables y mecanismos avanzados de IA.

Las mejoras introducidas permiten:

- Un mayor control sobre la memoria y rendimiento
- Supervisión detallada del estado interno
- Transparencia del proceso de razonamiento
- Respuestas más precisas y contextualizadas
- Un uso más eficiente de recursos
- Mayor seguridad y estabilidad general del sistema

El resultado es una plataforma sólida, moderna y apta para aplicaciones educativas, clínicas de apoyo o entornos de investigación, manteniendo buenas prácticas de IA responsable y explicable.